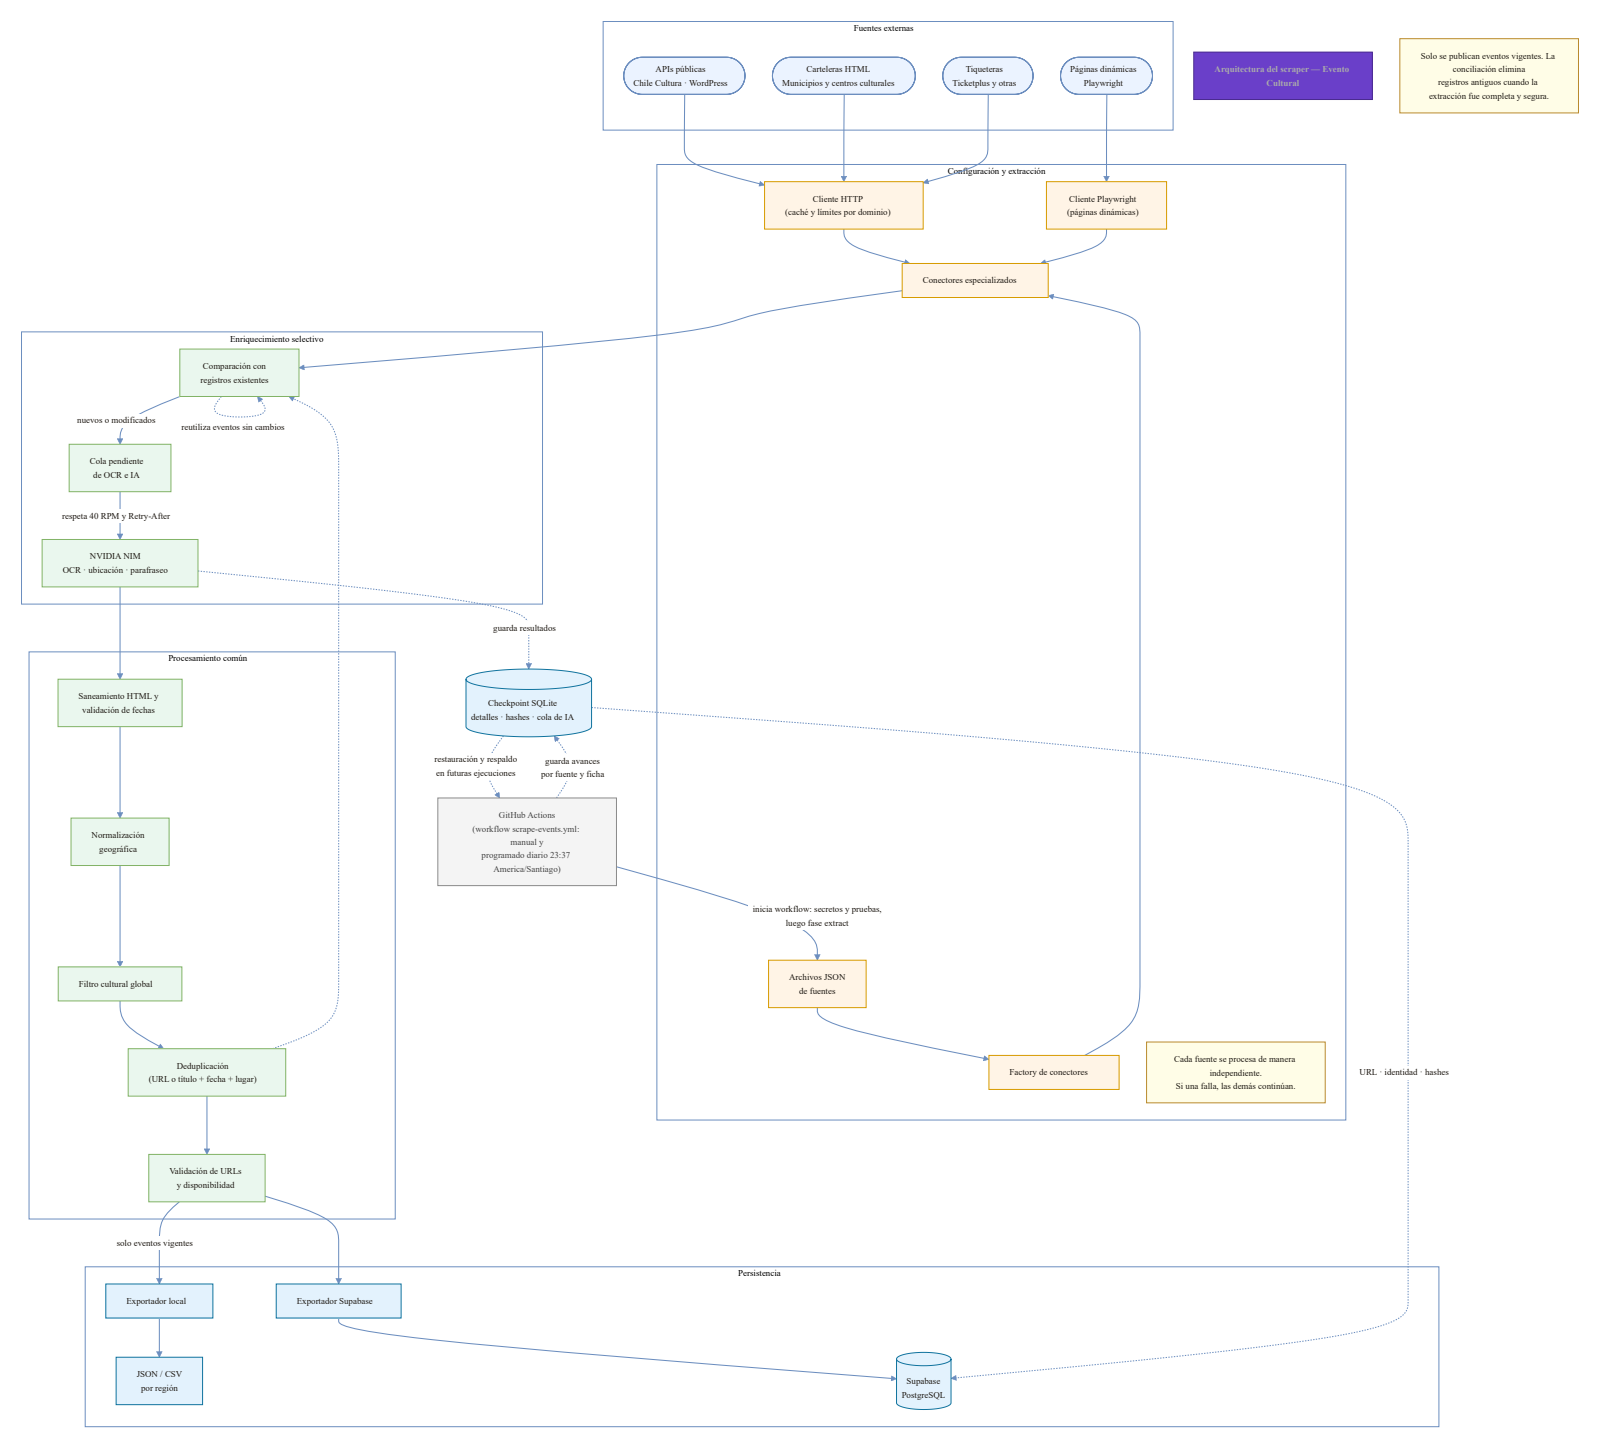

Fuentes externas
APIs públicas
Chile Cultura · WordPress
Carteleras HTML
Municipios y centros culturales
Tsqueteras
Ticketplus y otras
Páginas dinámicas
Playwright
Arquitectura del scraper — Evento Cultural
Solo se publican eventos vigentes. La conciliación elimina registros antiguos cuando la extracción fue completa y segura.
Configuración y extracción
Cliente HTTP
(caché y límites por dominio)
Cliente Playwright
(páginas dinámicas)
Conectores especializados
Enriquecimiento selectivo
Comparación con registros existentes
nuevos o modificados
reutiliza eventos sin cambios
Cola pendiente de OCR e IA
respeta 40 RPM y Retry-After
NVIDIA NIM
OCR · ubicación · parafraseo
guarda resultados
Procesamiento común
Saneamiento HTML y validación de fechas
Normalización geográfica
Filtro cultural global
Deduplicación
(URL o título + fecha + lugar)
Validación de URLs y disponibilidad
Checkpoint SQLite
detalles · hashes · cola de IA
restauración y respaldo en futuras ejecuciones
guarda avances por fuente y ficha
GitHub Actions
(workflow scrape-events.yml: manual y programado diario 23:37 America/Santiago)
inicia workflow: secretos y pruebas, luego fase extract
Archivos JSON de fuentes
Factory de conectores
Cada fuente se procesa de manera independiente.
Si una falla, las demás continúan.
URL · identidad · hashes
solo eventos vigentes
Persistencia
Exportador local
Exportador Supabase
JSON / CSV por región
Supabase PostgreSQL